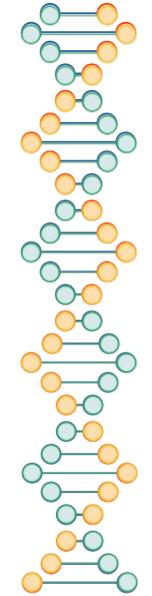


Déployez un modèle dans le cloud

Projet 7 Sofia Velasco

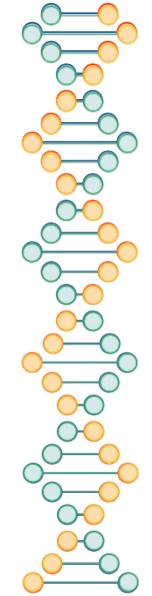




Objectif:

- 1.S'approprier des travaux préalables et les compléter (PCA, inférence distribuée).
- 2. Développement dans Databricks (Pyspark) et en utilisant le cloud AWS pour le stockage.





Création d'un compte AWS

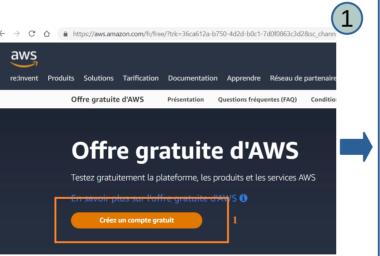
(Stockage dans le Cloud)

- A. Création d'un compte AWS
- B. Connexion au compte AWS
- C. Configuration du compte AWS
 - Création User
 - Création du Bucket sur S3

A. Création d'un compte AWS

(Option essais gratuit → valide 12 mois par défaut)

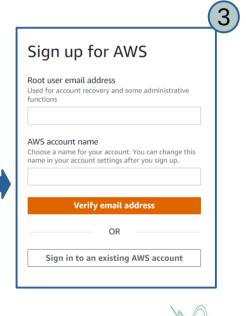
- Sur: https://aws.amazon.com/fr/free/



Note:

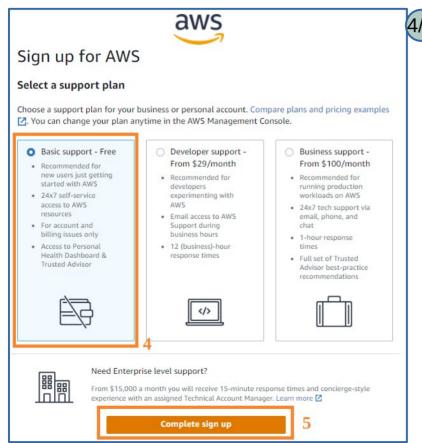
L'adresse mail devra être confirmée par un code. Informations personnelles dont **région (choisir France)** et coordonnées bancaire demandées.

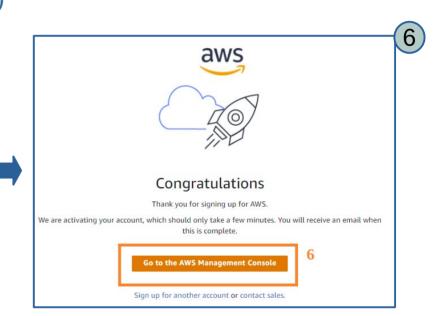




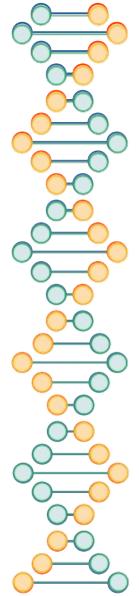
A. Création d'un compte AWS

(Option essais gratuit → valide 12 mois par défaut)

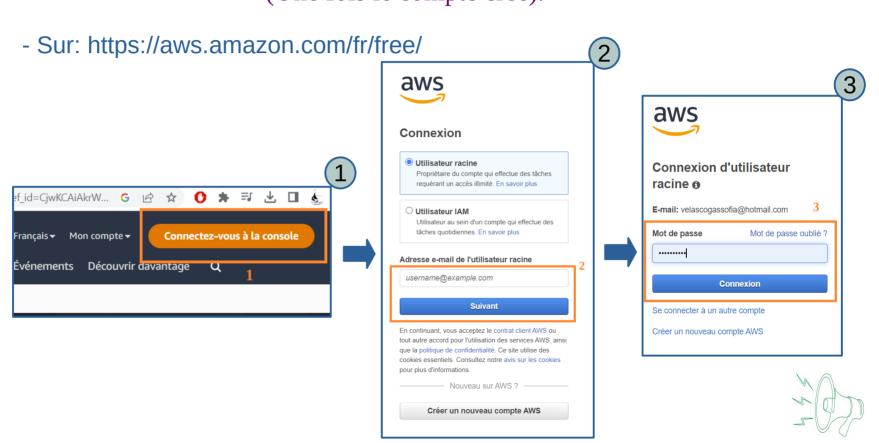




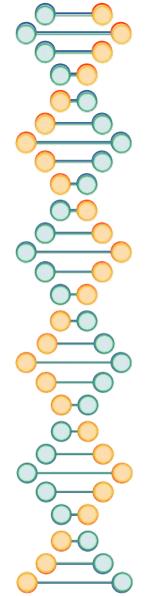




B. Connexion au compte AWS (Une fois le compte crée).

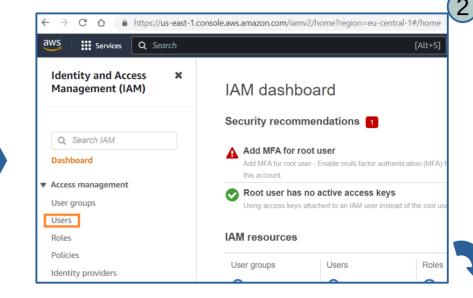


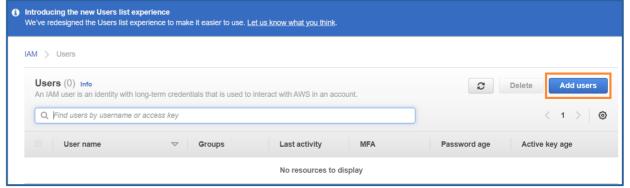
1ère connexion on arrive directement ici après création de compte.



C. Configuration du compte AWS (Console → Création User sur IAM).







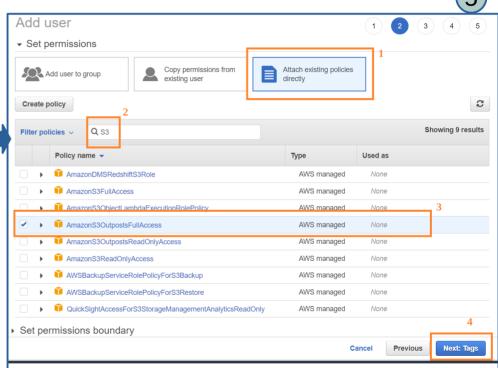


C. Configuration du compte AWS (Console → Création User). Add user Add user ▼ Set permissions Set user details Add user to group existing user You can add multiple users at once with the same access type and permissions. Learn more Create policy User name* Add another user Filter policies v **Q** S3 Policy name -Select AWS access type AmazonDMSRedshiftS3Role Select how these users will primarily access AWS. If you choose only programmatic access, it does NOT prevent users from accessing the console using AmazonS3FullAccess an assumed role. Access keys and autogenerated passwords are provided in the last step. Learn more AmazonS3ObjectLambdaExecutionRolePolicy Select AWS credential type* Access key - Programmatic access AmazonS3OutpostsFullAccess Enables an access key ID and secret access key for the AWS API, CLI, SDK, and other development tools. ▶ ■ AmazonS3OutpostsReadOnlyAccess AmazonS3ReadOnlyAccess Password - AWS Management Console access Enables a password that allows users to sign-in to the AWS Management Console.

Cancel

Next: Permissions

* Required







databricks

User from databricks

C. Configuration du compte AWS

(Console → Création User).

Remove

Next: Review

Cancel

Previous

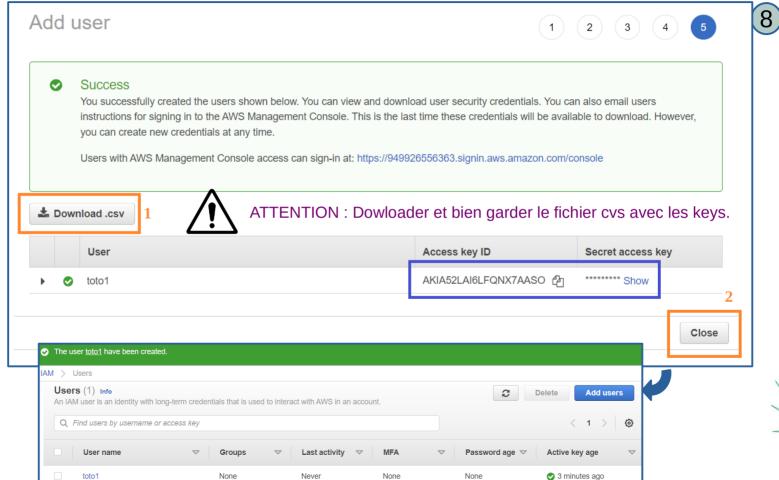
×

×

Add user			1	2 3	4
Review					
Review your choices.	After you create t	he user, you can view and download the autogenerated pass	word and access key.		
User details					
	User name	toto1			
AW	S access type	Programmatic access - with an access key			
Permissi	ons boundary	Permissions boundary is not set			
Permissions sumi	mary				
The following policies v	will be attached to	o the user shown above.			
Туре	Name				
Managed policy	AmazonS3Ou	utpostsFullAccess			
Tags					
The new user will rece	ive the following	tags			
Key		Value			
Name		databricks			
Use		User from databricks			

C. Configuration du compte AWS

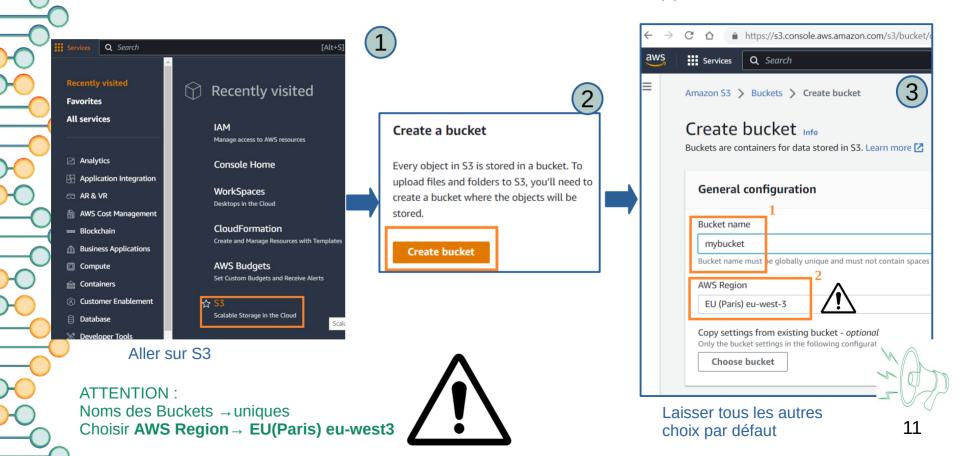
(Console → Création User).



C. Configuration du compte AWS

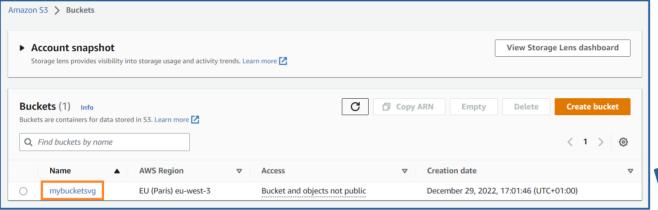
(Console → Création du Bucket sur S3).

Bucket = 'contenant' où se trouvent les fichiers et dossier à appeler avec Databricks.



C. Configuration du compte AWS

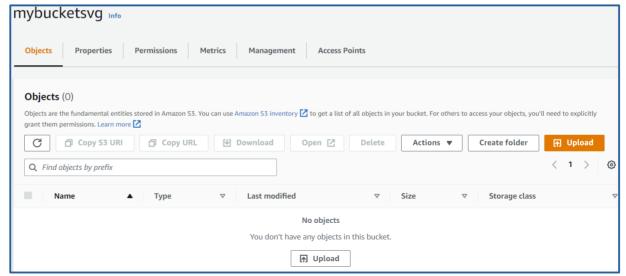
(Console → Création du Bucket sur S3).



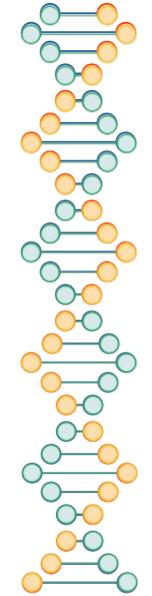


Dans ce bucket:

- On uploadera notre data
- -On retrouvera nos **résultats** obtenus en utilisant **Databricks**.





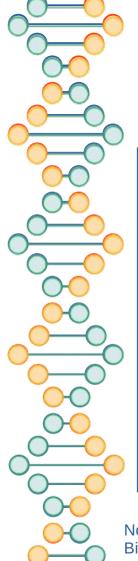


Création d'un compte Databricks.

Databricks → Plate-forme Web,

- pour: travailler avec Spark,
- avec: gestion automatisée des clusters et notebooks style IPython
- A. Création d'un compte Databricks
- B. Liaison avec le compte AWS (Création automatique du Workspace)
- C. Configuration du compte Databricks
 - Création Cluster
 - Création Notebook

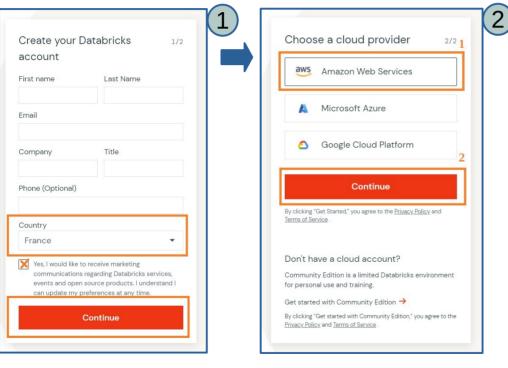




A. Création d'un compte Databricks

(Option essais gratuit → valide 14 jours)

- Sur: https://www.databricks.com/try-databricks#account





Note:

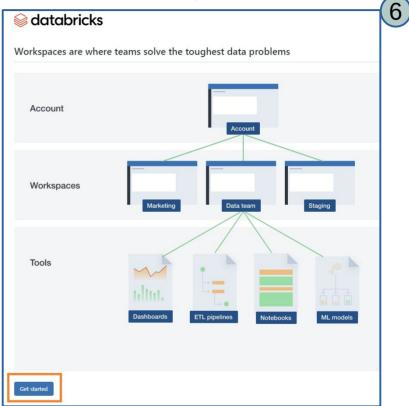
Bien sélectionner 'Country' → 'France'.

A. Création d'un compte Databricks

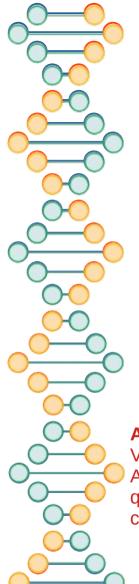
(Option essais gratuit → valide 14 jours)



Note: Prendre la version standard!







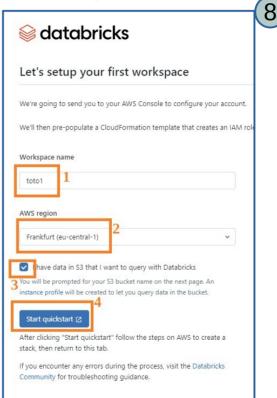
A. Création d'un compte Databricks

(Option essais gratuit → valide 14 jours)

⊗ databricks	7
To proceed, please confirm you have the following	
✓ An AWS account	
The password you used to setup your Databricks account	
A friendly name for your workspace	
Confirm	

ATTENTION:

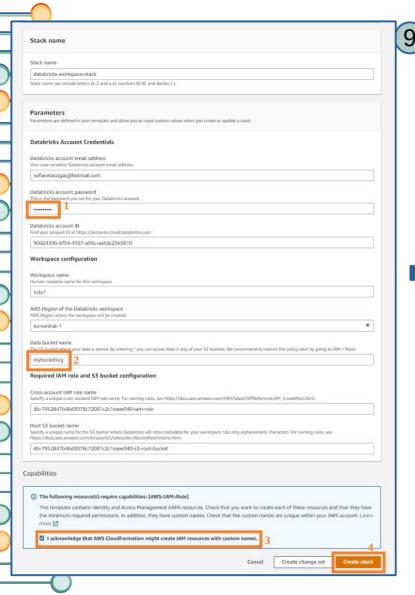
Vous devez être connectés à votre compte AWS, pour lancer le processus de 'quickstart' qui se chargera de lier le compte Databricks au compte AWS.



ATTENTION:

Prendre 'AWS Region' → Frankfurt (eu-central-1) Compatible avec la France pour le respect des contraintes du RGPD



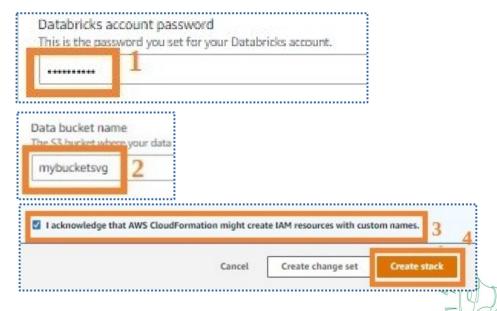


B. Liaison avec le compte AWS (Création automatique du Workspace)

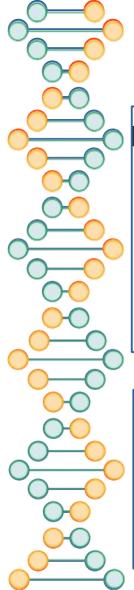
ATTENTION:

Remplir uniquement:

- le 'Databricks password' et
- le 'Data bucket name' → celui de notre AWS (où se trouvent les données)



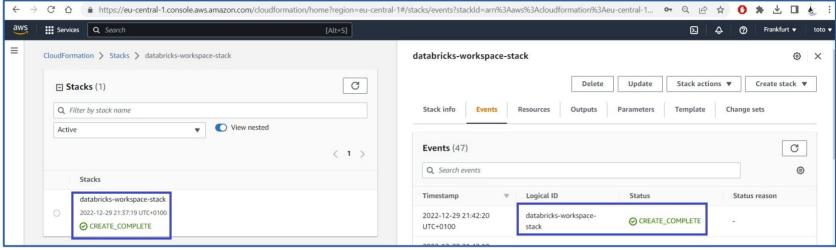
Ceci lie automatiquement le 'ID databricks' et le 'IAM role' de AWS



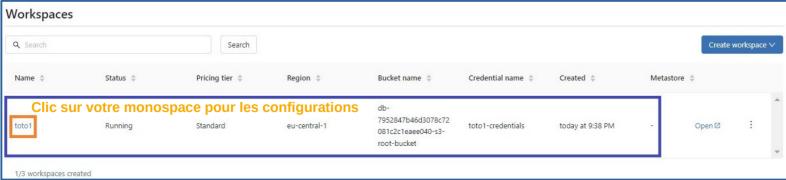
B. Liaison avec le compte AWS

(Création automatique du Workspace)

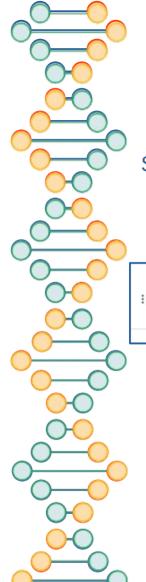
Sur notre AWS on verra alors:



Sur notre Databricks on verra alors:



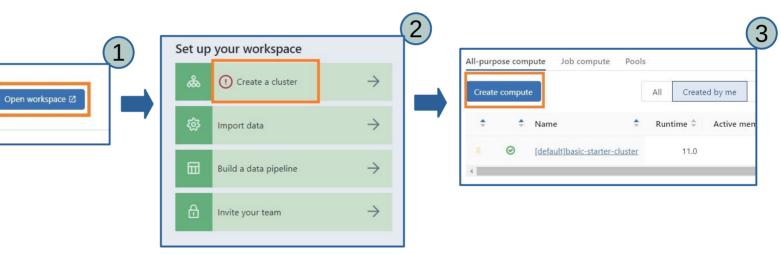


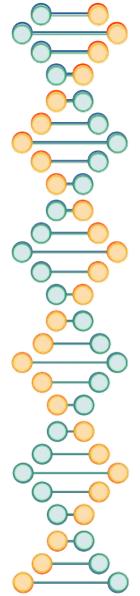


Update workspace

A. Configuration du compte Databricks (Création Cluster)

Suite à cliquer sur notre Workspace:

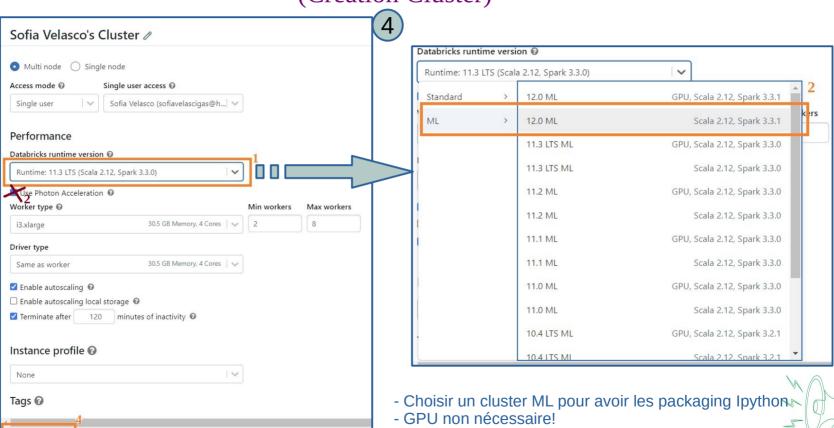




Create Cluster

Cancel

A. Configuration du compte Databricks (Création Cluster)

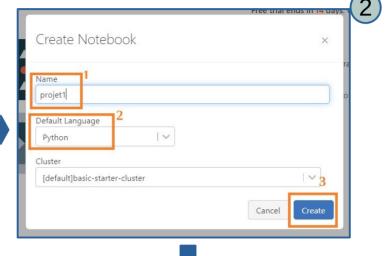


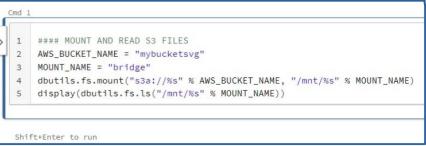
A. Configuration du compte Databricks (Création Notebook)

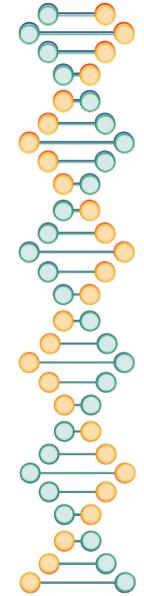




Mount à faire une seule fois! Après on peut coder!







Étapes de la chaîne de traitement (PySpark/Databricks)









Pourquoi PySpark et non pas Pandas?

Pandas → exécute des opérations sur une seule machine

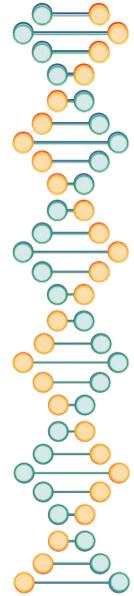
PySpark → exécute des opérations sur plusieurs machines.



Pour faire du Machine Learning où traiter des datasets volumineux, PySpark est la solution idéale:

Traitement des opérations plusieurs fois (100x) plus rapidement que Pandas, et sans crash.





B. Étapes de la chaîne de traitement (Spark et le modèle).

Création de Session Spark et Contexte → Nécessaires pour l'utilisation de Spark.

```
spark = (SparkSession
                                                                                       Spark Session - hive
              .builder
                                                                                       SparkContext
             .appName('P8')
              .master('local')
                                                                                       Spark UI
             .config("spark.sql.parquet.writeLegacyFormat", 'true')
                                                                                       Version
              .getOrCreate()
                                                                                            v3.3.1
                                                                                       Master
                                                                                            spark://10.75.188.178:7077
                                                                                       AppName
 ATTENTION:
                                                                                            Databricks Shell
 Une fois Spark lancé → tout se fait par Spark
```

• Le modèle:

'MobileNetV2' de TensorFlow (poids pré-calculés d'imagenet) → rapide et efficace.

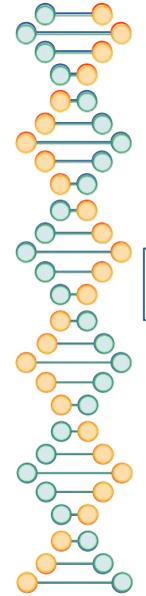
```
model = MobileNetV2(weights='imagenet', include_top=True, input_shape=(224, 224, 3))
```

Sans deuxième couche.

```
new_model = Model(inputs=model.input, outputs=model.layers[-2].output)
```

 Avec broadcast de ses poids (sur tous les processeurs de Spark) → plus rapide brodcast_weights = sc.broadcast(new_model.get_weights())

 Récupération du vecteur des features de dimensions (1,1,1280) → mis dans des moteur de classification reconnaîtra les différents fruits



B. Étapes de la chaîne de traitement (Les images).

Chargement des images:
 Format binaire → permet de séparer facilement un objet de l'arrière-plan.

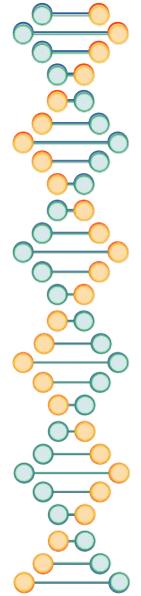
```
images = spark.read.format("binaryFile") \
    .option("pathGlobFilter", "*.jpg") \
    .option("recursiveFileLookup", "true") \
    .load(PATH_Data)
```

```
▶ (1) Spark Jobs
▶ ■ images: pyspark.sql.dataframe.DataFrame = [path: string, modificationTime: timestamp ... 3 more fields]
 |-- path: string (nullable = true)
 |-- modificationTime: timestamp (nullable = true)
 |-- length: long (nullable = true)
 |-- content: binary (nullable = true)
 |-- label: string (nullable = true)
           Deux colonnes: 'path' et 'label'
                                                    Ilabel
|dbfs:/mnt/bridge/Test/apple hit 1/r0 167.ipg
                                                    lapple hit 1
|dbfs:/mnt/bridge/Test/apple hit 1/r1 51.jpg
                                                    lapple hit 1
|dbfs:/mnt/bridge/Test/cabbage_white_1/r0_139.jpg|cabbage_white_1|
|dbfs:/mnt/bridge/Test/cabbage_white_1/r0_71.jpg |cabbage_white_1|
|dbfs:/mnt/bridge/Test/cabbage white 1/r0 103.jpg|cabbage white 1|
only showing top 5 rows
```

ATTENTION:

- On n'entraîne pas le modèle → **uniquement dossier 'TEST**'.
- Base de données très réduite (3 images par fruits) du dossier 'TEST' → ne pas dépasser les versions moins chères de AWS, et test de Databricks.





B. Étapes de la chaîne de traitement (Traitement des images et Featurize).

- 3 Fonctions auxiliaires (liées entre elles):
 - Traitement des images.

Size: (224,224) → besoins du modèle. Array: conversion RVB en BGR → compatible TensorFlow.

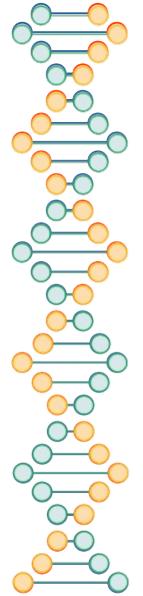
```
def preprocess(content):
    img = Image.open(io.BytesIO(content)).resize([224, 224])
    arr = img_to_array(img)
    return preprocess_input(arr)
```

Featurize d'une série pandas d'images, en utilisant un modèle.
 Prédiction avec modèle → obtention des features.
 En retour → série pandas des features des images.

```
def featurize_series(model, content_series):
    input = np.stack(content_series.map(preprocess)) #on stack (ajoute des arries) et applique la focntion process définie auparavant.
    preds = model.predict(input) #on predit avec le modèle choisi.
    output = [p.flatten() for p in preds] #on applatit les tenseur.
    return pd.Series(output)
```

Note: les features peuvent être des tenseur multidimensionnels → 'flatten', supprimer toute leurs dimensions sauf une.





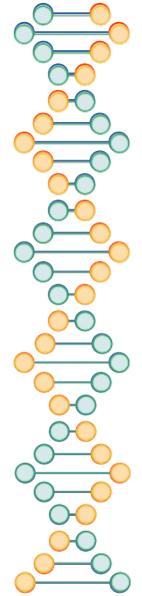
B. Étapes de la chaîne de traitement (Pandas UDF).

- Pandas UDF (batches et définition du modèle).
 - Scalar Iterator pandas UDFs' → load modèle une fois et le réutilise pour plusieurs 'bacthes' (lots) de données → amortit coût en temps et mémoire.
 - En retour → une colonne 'Spark DataFram' de type ArrayType(FloatType).
 - 'content_series_iter' → itérateur sur des 'batches' (lots) de data. Chaque 'batch' est un 'pandas Series' d'images.

```
@pandas_udf('array<float>', PandasUDFType.SCALAR_ITER)
def featurize_udf(content_series_iter):
    model = model_fn()
    for content_series in content_series_iter:
        yield featurize_series(model, content_series)
```

Batches + Modèle aux poids broadcastés

'Distributed model inference using TensorFlow Keras'.



B. Étapes de la chaîne de traitement (Extraction des Features).

Extraction des Features sur nos images.

ATTENTION:

- '.rrepartition()' → crée des 'bacthes' d'images. On en crée 24 → 24 fichier parguet à la fin.
- Le nombre de lots choisit car 24 types de fruits (ie. 24 dossiers).

Résultats:

```
f_pandas=features_df.toPandas()
f_pandas.loc[0,'features'].shape

Out[112]: (1280,)
f_pandas.shape

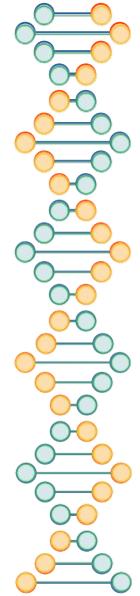
Out[114]: (72, 3)
```



On a bien:

- Des vecteurs de 1280 features
- 72 lignes (3 fruits x 24 types)
- 3 colonnes: 'path', 'label' (initiales) + features





B. Étapes de la chaîne de traitement (PCA).

PCA → Réduction de dimension des Feature Vectors.

```
PCA en PySpark → from pyspark.ml.feature import PCA

Pour appliquer le PCA 'features' doit être: 'VectorUDT' et non 'ArrayType'.

from pyspark.ml.linalg import Vectors, VectorUDT

list_to_vector_udf = udf(lambda l: Vectors.dense(l), VectorUDT())

features_df2 = features_df2.select(col("*"), list_to_vector_udf(features_df2["features"]).alias("features_2"))

pca = PCA(k=50, inputCol="features_2", outputCol="pcaFeatures")

model_pca = pca.fit(features_df2)
```

ATTENTION: on fixe 50 features (ie. k=50) car ça explique aux alentours de 95 % de la variance.

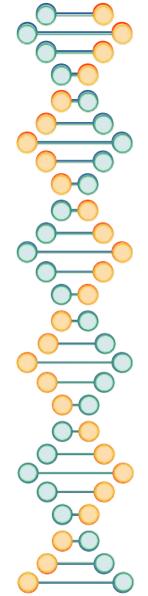
Résultats:

result = model_pca.transform(features_df2)

On a bien:

- Des vecteurs de 50 features
- 72 lignes (3 fruits x 24 types)
- 5 colonnes: 'path', 'label' (initiales) + features +features_2 (vecteur) +pcaFeatures (réduite)

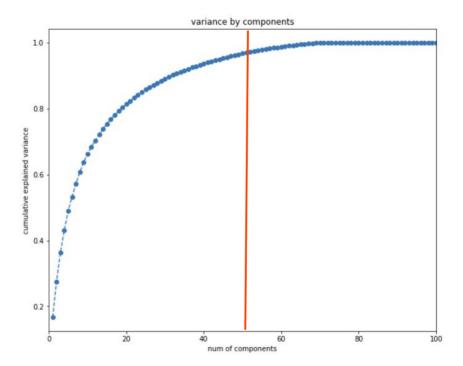




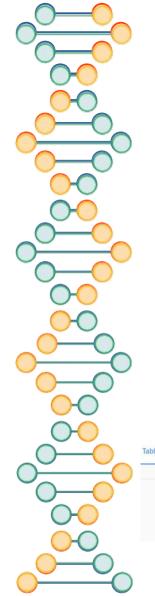
B. Étapes de la chaîne de traitement (PCA).

ATTENTION:

on fixe 50 features (ie. k=50) car ça explique aux alentours de 95 % de la variance.







B. Étapes de la chaîne de traitement (Enregistrement sur S3 → 'parquet').

Enregistrement des Features obtenus en format 'parquet' sur S3.

'Apache Parquet' → format pour stocker de très gros volumes de données ayant une structure «complexe». Facilite distribution de la charge de traitement, et sa structuration exclue rapidement des pans entiers du jeu de données → réduit temps de traitement.

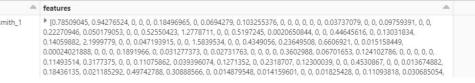
```
#K.1 Résultats avant PCA.
features_df.write.mode("overwrite").parquet(PATH_Result)
#K.2 Résultats après PCA.
result.write.mode("overwrite").parquet(PATH_Result_PCA)
```

Lecture des fichiers 'parquet' obtenus et sauvegardées en S3.

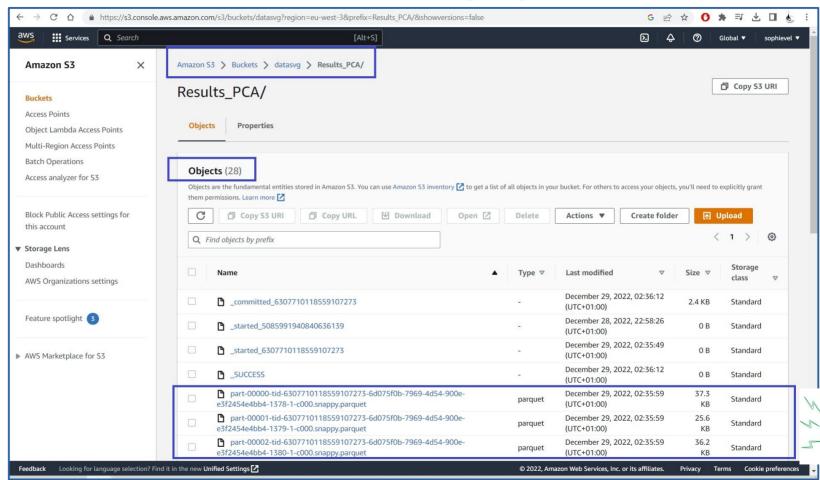
Avec 'spark.read.parquet', en pointant sur le répertoire principal on charge tous les fichiers du répertoire de type parquet.

```
df = spark.read.parquet(PATH_Result, engine='pyarrow')
display(df)
```

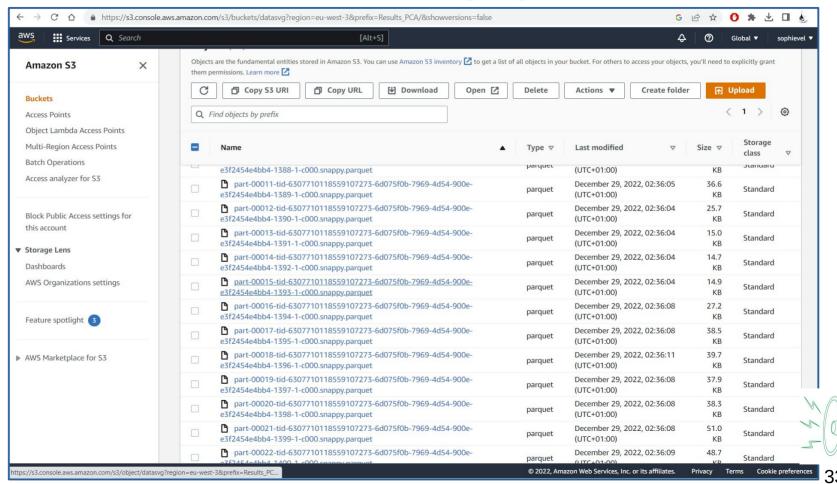
dbfs:/mnt/bridge/Test/apple_granny_smith_1/r1_251.jpg

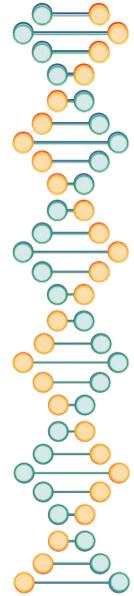


C. Visualiser les fichiers 'parquet' sur AWS



C. Visualiser les fichiers 'parquet' sur AWS

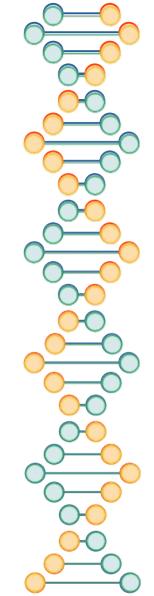




Limites et améliorations

- L'utilisation de Spark, accélère beaucoup le processus des calculs, c'est extrêmement rapide comparé à pandas.
- Databricks est un environnement simple d'utilisation qui étant lié à AWS nous facilite beaucoup la tâche tout en pouvant stocker de grosses bases de données sur le web.
- AWS est très puissant. Il permet de réaliser plein de choses au-delà de sa liaison avec Databricks. L'unique soucis c'est la question des coups.

 L'utilisation de ces outils est donc franchement recommandée, mais il convient d'utiliser une stratégie adapté aux rapport besoin/coups de la boîte pour ne pas se retrouver avec quelque chose qui rapporte moins que ce qu'il coûte



MERCI

